\_\_\_\_\_\_

## TP2 Le traitement Batch avec Hadoop HDFS- MapReduce

------

## Map Reduce

## Présentation

Un Job Map-Reduce se compose principalement de deux types de programmes :

- Mappers : permettent d'extraire les données nécessaires sous forme de clef/valeur, pour pouvoir ensuite les trier selon la clef
- **Reducers** : prennent un ensemble de données triées selon leur clef, et effectuent le traitement nécessaire sur ces données (somme, moyenne, total...)

## Wordcount

Nous allons tester un programme MapReduce grâce à un exemple très simple, le *WordCount*, l'équivalent du *HelloWorld* pour les applications de traitement de données. Le Wordcount permet de calculer le nombre de mots dans un fichier donné, en décomposant le calcul en deux étapes:

- L'étape de *Mapping*, qui permet de découper le texte en mots et de délivrer en sortie un flux textuel, où chaque ligne contient le mot trouvé, suivi de la valeur 1 (pour dire que le mot a été trouvé une fois)
- L'étape de *Reducing*, qui permet de faire la somme des 1 pour chaque mot, pour trouver le nombre total d'occurrences de ce mot dans le texte.

Commençons par créer un projet Maven dans IntelliJ IDEA. Nous utiliserons dans notre cas JDK 1.8.

- Définir les valeurs suivantes pour votre projet:
  - **GroupId**: hadoop.mapreduce
  - ArtifactId: wordcount
  - Version: 1
- Ouvrir le fichier *pom.xml*, et ajouter les dépendances suivantes pour Hadoop, HDFS et Map Reduce:

- Créer un package ma.ensam.tp1 sous le répertoire src/main/java
- Créer la classe TokenizerMapper, contenant ce code:

```
package ma.ensam.tp1;
import org.apache.hadoop.io.IntWritable;
import org.apache.hadoop.io.Text;
import org.apache.hadoop.mapreduce.Mapper;
import java.io.IOException;
import java.util.StringTokenizer;
public class TokenizerMapper extends Mapper<Object, Text, Text,
IntWritable> {
   private final static IntWritable one = new IntWritable(1);
   private Text word = new Text();
   public void map(Object key, Text value, Mapper.Context context) throws
IOException, InterruptedException {
         StringTokenizer itr = new StringTokenizer(value.toString());
         while (itr.hasMoreTokens()) {
                word.set(itr.nextToken());
                context.write(word, one);
         }
   }
```

• Créer la classe IntSumReducer.

```
package ma.ensam.tp1;
import org.apache.hadoop.io.IntWritable;
import org.apache.hadoop.io.Text;
import org.apache.hadoop.mapreduce.Reducer;
import java.io.IOException;
```

Enfin, créer la classe WordCount.

```
package ma.ensam.tp1;
import org.apache.hadoop.conf.Configuration;
import org.apache.hadoop.fs.Path:
import org.apache.hadoop.io.IntWritable;
import org.apache.hadoop.io.Text;
import org.apache.hadoop.mapreduce.Job;
import org.apache.hadoop.mapreduce.lib.input.FileInputFormat;
import org.apache.hadoop.mapreduce.lib.output.FileOutputFormat;
public class WordCount {
      public static void main(String[] args) throws Exception {
            Configuration conf = new Configuration();
            Job job = Job.getInstance(conf, "word count");
            job.setJarByClass(WordCount.class);
            job.setMapperClass(TokenizerMapper.class);
            job.setCombinerClass(IntSumReducer.class);
            job.setReducerClass(IntSumReducer.class);
            job.setOutputKeyClass(Text.class);
            job.setOutputValueClass(IntWritable.class);
            FileInputFormat.addInputPath(job, new Path(args[0]));
            FileOutputFormat.setOutputPath(job, new Path(args[1]));
            System.exit(job.waitForCompletion(true)? 0:1);
      }
```

LANCER MAP REDUCE SUR LE CLUSTER¶

Dans votre projet Eclipse:

- Créer une configuration Maven avec la ligne de commande: package install
- Lancer la configuration. Un fichier *job-0.0.1-SNAPSHOT.jar* sera créé dans le répertoire *target* du projet.
- Taper la commande suivante :

docker cp job-0.0.1-SNAPSHOT.jar hadoop-master:/root/ job-0.0.1-SNAPSHOT.jar

 Revenir au shell du contenaire master, et lancer le job map reduce avec cette commande:

hadoop jar job-0.0.1-SNAPSHOT.jar ma.ensam.tp1.WordCount input output

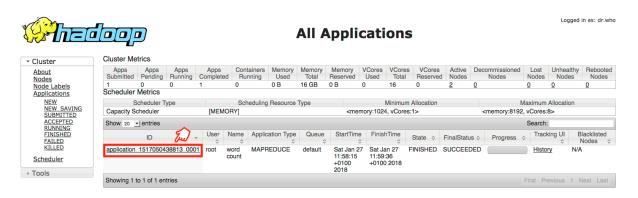
Le Job sera lancé sur le fichier *purchases.txt* que vous aviez préalablement chargé dans le répertoire *input* de HDFS. Une fois le Job terminé, un répertoire *output* sera créé. Si tout se passe bien, vous obtiendrez un affichage ressemblant au suivant:

```
[root@hadoop-master:~# hadoop jar wordcount-1.jar tn.insat.tp1.WordCount input output
18/81/27 10:58:13 INFO client.RMProxy: Connecting to ResourceManager at hadoop-master/172.22.0.2:8032
[18/81/27 10:58:14 WARN mapreduce.JobRsourceUploader: Hadoop command-line option parsing not performed. Implement the Tool interface and execute y
our application with ToolRunner to remedy this.
18/01/27 10:58:14 INFO input.FileInputFormat: Total input paths to process: 1
18/01/27 10:58:14 INFO mapreduce.JobSubmitter: number of splits:1
18/01/27 10:58:15 INFO mapreduce.JobSubmitter: Submitting tokens for job: job_1517050438813_0001
18/01/27 10:58:15 INFO impl.YarnClientImpl: Submitting tokens for job: job_1517050438813_0001
18/01/27 10:58:16 INFO mapreduce.Job: The url to track the job: http://hadoop-master:8088/proxy/application_1517050438813_0001
18/01/27 10:58:16 INFO mapreduce.Job: Running job: job_1517050438813_0001
18/01/27 10:58:29 INFO mapreduce.Job: Job job_1517050438813_0001
18/01/27 10:58:29 INFO mapreduce.Job: map 0% reduce 0%
18/01/27 10:58:29 INFO mapreduce.Job: map 0% reduce 0%
18/01/27 10:59:37 INFO mapreduce.Job: map 100% reduce 0%
18/01/27 10:59:37 INFO mapreduce.Job: map 100% reduce 0%
18/01/27 10:59:37 INFO mapreduce.Job: map 100% reduce 0%
18/01/27 10:59:37 INFO mapreduce.Job: Dob job_1517050438813_0001 completed successfully
18/01/27 10:59:37 INFO mapreduce.Job: map 100% reduce 100%
18/01/27 10:59:37 INFO mapreduce.Job: Dob job_1517050438813_0001 completed successfully
18/01/27 10:59:37 INFO mapreduce.Job: counters: 49
FILE: Number of bytes written=4086870
FILE: Number of bytes written=4086870
FILE: Number of large read operations=0
FILE: Number of large read operations=0
                                                                                                                                  FILE: Number of bytes written=4086870 FILE: Number of read operations=0 FILE: Number of large read operations=0 FILE: Number of write operations=0 HDFS: Number of bytes read=44337931 HDFS: Number of bytes written=491081 HDFS: Number of read operations=0 HDFS: Number of large read operations=0 HDFS: Number of write operations=0 HDFS: Number of write operations=2 nters
                                                                       Job Counters
                                                                                                                                      Launched map tasks=1
                                                                                                                                  Launched map tasks=1
Launched reduce tasks=1
Data-local map tasks=1
Total time spent by all maps in occupied slots (ms)=57326
Total time spent by all reduces in occupied slots (ms)=6032
Total time spent by all reduce tasks (ms)=57326
Total time spent by all reduce tasks (ms)=6032
Total tocore-milliseconds taken by all map tasks=57326
Total vcore-milliseconds taken by all reduce tasks=6032
Total mapayte-milliseconds taken by all map tasks=58701824
Total magabyte-milliseconds taken by all reduce tasks=6176768
usee Framework
                                                                                                                              Total megabyte-milliseconds taken by all redu
luce Framework
Map input records=868279
Map output records=5872188
Map output bytes=67826564
Map output bytes=67826564
Map output materialized bytes=1284159
Input split bytes=120
Combine input records=5872188
Combine output records=101438
Reduce input groups=58766
Reduce input groups=58766
Reduce shuffle bytes=1284159
Reduce input records=101438
Reduce output records=104438
Reduce output records=104438
Reduce output records=104438
Reduce Day output records=105766
Spilled Records=304314
Shuffled Maps =1
Failed Shuffles=0
Merged Map outputs=1
GC time elapsed (ms)=225
CPU time spent (ms)=51590
Physical memory (bytes) snapshot=549974016
Virtual memory (bytes) snapshot=1775112192
Total committed heap usage (bytes)=292028416
                                                                       Map-Reduce Framework
                                                                      Shuffle Errors
BAD_ID=0
CONNECTION=0
                                                                                                                                        IO ERROR=0
                                                                                                                                        WRONG LENGTH=0
                                                                                                                                      WRONG MAP=0
                                                                                                                                        WRONG_REDUCE=0
                                                                      File Input Format Counters
Bytes Read=44337811
                                                                       File Output Format Counters
                                                                                                                                      Bytes Written=491081
```

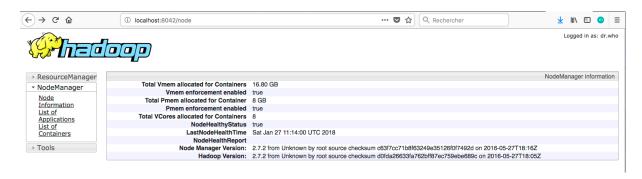
En affichant les dernières lignes du fichier généré *output/part-r-00000*, avec hadoop fs - tail output/part-r-00000, vous obtiendrez l'affichage suivant:

Petersbu	irg	8430
Philadel	lphia	8471
Phoenix	8431	
Pittsbur	gh	8470
Plano	8323	
Portland	1	8367
Raleigh	8345	
Reno	8334	
Richmond		8388
Riverside		8338
Rochester		8440
Rouge	8396	
Sacramer	nto	8597
Saint	8494	
San	42110	
Santa	8416	
Scottsda		8443
Seattle		
Spokane	8356	
Sporting		48207
Springs	8534	
St.	16881	
Stockton		8289
Supplies		48265
Tampa	8400	
	8314	
	48463	
	8546	
Tulsa	8444	
9	16957	
	48439	
Virginia		8465
Visa	174018	
	8510	
Washingt		8477
	8527	
Wichita	8547	
Winston-		8459
Women's		
	8462	
	8529	
and	48408	

Il vous est possible de monitorer vos Jobs Map Reduce, en allant à la page: http://localhost:8088. Vous trouverez votre Job dans la liste des applications comme suit:



Il est également possible de voir le comportement des noeuds esclaves, en allant à l'adresse: http://localhost:8041 pour *slave1*, et http://localhost:8042 pour *slave2*. Vous obtiendrez ce qui suit:



Écrire un Job Map Reduce permettant, à partir du fichier purchases initial, de déterminer le total des ventes par magasin.